



# 抖音端智能优化用户体验 的探索和实践

陈贻东


# 讲师自我介绍



## 陈贻东

2016年硕士毕业于中国科学技术大学，校招加入腾讯手机QQ团队，从事QQ Android端基础功能研发和新技术探索。

2020年加入字节跳动抖音基础技术团队，负责探索端智能技术优化抖音用户体验方向的工作，包括建设抖音端智能基础能力、挖掘端智能技术应用场景、落地端智能解决方案。



- 
- 01 背景：为什么要在抖音做端智能优化体验？
  - 02 抖音端智能实践案例
  - 03 抖音端智能架构设计
  - 04 总结 & 展望

# 01

背景：为什么要在抖音做端智能优化体验？

# 01\_背景 – 端智能是什么

关键词：人工智能、机器学习、深度学习、强化学习、神经网络 ...




## 01\_背景 – 端智能是什么


端智能（On-Device Machine Learning），是指把机器学习应用和部署到端设备上，这里“端设备”是相对于云服务而言的，可以是手机、平板，也可以是物联网IoT设备。




抖音换装特效



淘宝AR试装



手势&手指检测




左手右手操作识别

# 01\_背景 – 端智能的优势和不足

端智能有哪些优势？

- 低延迟 (Low Latency)
- 离线工作 (Works offline)
- 低成本 (Low Cost)
- 隐私 (Privacy)





端智能也存在其不足之处

- 端设备上算力、内存、存储和功耗相对云侧是受限制的，意味着模型大小和功能会受限。



## 01\_背景 – 抖音用户体验优化需要端智能技术

1. 用户深层次需求、个性化体验，需要端智能技术，规则判断向智能决策进阶。
2. 端云协同，合理分配任务，发挥端与云各自优势，进一步提升抖音体验，如端云协同优化推荐效果。
3. 技术创新增加内在推动力，通过端智能技术感知用户实时信息，为业务提供更多手段探索和提升用户体验，助力业务尝试和突破。





# 02

## 抖音端智能实践案例

## 02\_ 抖音端智能实践案例




智能决策

智能感知

端云协同


# 02\_ 抖音端智能实践案例 – 智能决策：视频智能预加载

背景：在抖音短视频feed流场景，一种提升播放体验非常有效的手段是提前预加载视频部分缓存，让视频被观看时能快速起播。



## 02\_ 抖音端智能实践案例 – 智能决策：视频智能预加载

问题：用户每个视频的播放时长（大小）存在差异性，采用单一的预加载策略存在浪费和rebuffer风险。



Case 1 采用预加载策略 1（少）更合适，Case 2 采用预加载策略 2（多）更合适。


用户播放体验与预加载效率直接相关，提升视频预加载效率的关键是使预加载大小和播放大小尽量匹配。

## 02\_ 抖音端智能实践案例 – 智能决策：视频智能预加载

怎样使预加载大小和播放大小匹配？

- 借助端智能技术，**预知**用户播放视频时长（大小），以此作为视频预加载大小的依据，提升预加载效率。
- **然而**，单视频播放时长具有一定随机性，并且依赖视频内容和用户偏好，很难精确预测视频播放长度。
- **但是**，用户在一段时间内的播放习惯（fast、slow、normal）是可识别的。


Previous N videos



**智能决策：**预判未来X个视频播放习惯，决定预加载大小。

## 02\_ 抖音端智能实践案例 – 智能决策：视频智能预加载

方案落地：




上线效果：应用端智能决策组相比于对照组，**预加载效率提升**，用户的整体**卡顿有明显下降**，**播放流畅度提升**，带动用户播放时长增加，助力核心播放业务提升。

## 02\_ 抖音端智能实践案例 – 智能决策：视频智能预加载

方案进阶：

- 结合播放习惯（fast、slow、normal）预测，动态调整空闲状态，智能控制触发预加载时机。平衡预加载任务和当前播放下载任务，带来成本收益。




继续探索：


- 模型上：端云结合挖掘更多有价值特征提升决策准确率；做更多更细粒度的播放时长相关预测，作为业务调优依据。
- 业务上：做更细粒度的预加载大小和数量的策略调优，更加精准控制预加载触发时机。



## 02\_ 抖音端智能实践案例 – 智能决策：评论精准智能预加载



### 评论页面加载过程



问题：整个过程中主要耗时点是数据请求加载耗时。

怎么优化？提前预加载。


A/B实验：在视频开始播放2s后，提前预加载评论数据。  
(规则)

验证效果：用户打开评论列表的展现耗时大幅降低，进评论次数显著增加。**但是，评论列表服务QPS暴增。**

原因：假设用点击评论/视频 = 20%，直接预加载导致请求量增加4倍，ROI严重失衡。

## 02\_ 抖音端智能实践案例 – 智能决策：评论精准智能预加载

精准智能预加载方案：加入端智能技术，预测用户是否会去点击评论按钮，预测值  $\text{score} > \text{threshold}$  时再做预加载。



上线效果：高峰期间+3.5%QPS情况下，带来20%+预加载命中，评论展现耗时降低，用户体验提升，进评论业务提升。

未来进阶：挖掘更多有价值特征，尝试更多技术手段，如端云结合、端上训练/强化学习，提升智能决策准召，带来更大业务收益。

# 02\_ 抖音端智能实践案例 – 智能决策：小结

## 探索智能决策场景技巧

- 当一处业务场景，有2个或多个策略可选，并且这些策略都各自有优缺点，那么：
  - Step 1 找到大盘最优解。
  - Step 2 分人群/设备等寻找大规模群体的局部更优解。
  - Step 3 寻找适合的目标，通过端智能技术做智能决策，更细粒度的获得业务更优策略。

## 抖音其他智能决策场景探索概览

|                 |                                      |
|-----------------|--------------------------------------|
| Feed智能Load More | 预测剩余视频播放时长，智能决策是否提前触发 load more 操作。  |
| 智能编码            | 智能决策发布上传视频的编码方式，如硬件编码、软件编码、省略二次编码。   |
| 智能分片上传          | 智能决策发布上传视频网络数据包的分片大小，如128K、256K .... |
| 智能超分            | 智能决策是否启用视频超分策略。                      |
| 智能选档            | 智能决策视频播放起播码率档位。                      |
| 智能预渲染时机         | 智能决策预渲染下一个视频首帧的时机。                   |
| 页面智能预加载         | 更多业务场景的页面、数据的智能决策是否预加载。              |

## 02\_ 抖音端智能实践案例



智能决策


智能感知

端云协同

## 02\_ 抖音端智能实践案例 – 智能感知：左右手识别

什么是左右手识别？

- 应用端智能技术识别出用户是左手、还是右手在操作滑动手机。




左手拇指操作  
舒适区



右手拇指操作  
舒适区

# 02\_ 抖音端智能实践案例 – 智能感知：左右手识别



怎么识别？



## 数据格式


- X样本: [p0, p1, p2, p3, p4, ... ], p= (x, y, w, h, density, dtime) 。
- Y样本: left / right

## 02\_ 抖音端智能实践案例 – 智能感知：性能劣化状态预感知



## 02\_ 抖音端智能实践案例 – 智能感知：小结

应用端智能技术实时感知用户操作、时空环境、设备状态，为业务提供更多通用优化手段。





## 02\_ 抖音端智能实践案例



智能决策


智能感知

端云协同

## 02\_ 抖音端智能实践案例 – 端云协同


端和云相互补充、协同，合理分配任务，  
寻找最优解。

实时感知用户的操作  
和时空行为，作为特  
征辅助优化云端推荐  
效果。



# 02\_ 抖音端智能实践案例 — 总结


端智能技术应用案例的探索和实践流程



# 03


## 抖音端智能架构设计

# 03\_ 抖音端智能架构设计 — 端智能解决方案框架



# 03\_ 抖音端智能架构设计 – 特征中心

建设目的：提高复用性；提高动态性；数据一致性。



端上特征中心架构

# 04

## 总结 & 展望

## 04\_总结

端智能（On-Device Machine Learning）：低延迟、隐私、离线工作、低成本，但模型大小受限。

智能决策：视频智能预加载，评论精准智能预加载。


智能感知：左右手识别，性能劣化状态预感知。

端云协同：端和云相互补充、协同，优化推荐和端模型。

抖音端智能架构设计 & 特征中心架构。



## 04\_展望



## 04\_成长路线

入门（端智能工程师）：对端智能技术有一定认知，可协作完成端智能技术在业务场景上的需求落地。

### 机器学习 & 端智能技术入门资料

- 了解端智能可以做哪些事情：[Google MLKit](#)、[华为MLKit](#)
- 机器学习入门：[Tensorflow入门](#)、[机器学习速成课](#)、[微软AI-EDU](#)
- 机器学习在移动端应用：[TensorflowLite入门](#)
- 机器学习原理：[吴恩达课程](#)

进阶（端智能架构师）：掌握移动端技术、机器学习技术、数据分析能力，深耕所属业务，站在更全局视野上设计端上智能解决方案，建设端上智能架构。



**THANKS.**