

腾讯视频

端智能实践中的破局之路

腾讯视频端智能负责人/ 汪洋

大纲

- 背景介绍
- 端智能体系的思考
- 业务实践
- 未来规划

背景介绍

传统内容推荐的挑战

1

实时反馈

分页机制下，内容干预不及时

2


实时感知

用户反馈行为经过流处理平台存在时延

3

特征粒度粗

受限于云侧成本，只能选择频次较低的用户行为特征上报



为什么是端智能



富交互

端内可以采集更丰富的用户反馈行为



高实时

真正实现毫秒级延迟



低成本

充分利用终端算力与存储空间



强隐私

本地处理数据对用户更安全

端智能好落地吗？

1 数据特征工作难

数据与特征难索引，难复用


算法提需求，终端转译算法规则，
门槛高效率低



2 算法迭代周期长

数据迭代依赖终端发版，模型训练
周期拉长

训练好的模型需要额外端上配合验证



3 跨技术栈协同成本高




1.数据、特征工作能不能让我自己来做？
2.能不能直接去终端调试验证我的算法结果？




1.能不能不去理解这些具体的机器学习概念呢？
2.我更关注如何去应用推理的结果

端智能场景协同现状



端智能场景协同期望



端智能体系的思考

设计思路

端数据体系标准化，核心链路搭建

包括数据供给与计算、特征加工与存储、算法行为逻辑、模型资源管理等，都应该具备标准化、开箱即用的能力

核心算法过程动态化

从数据准备、特征加工，到决策触发、推理调用，以及模型的部署更新，都需要一整套统一的动态化解决方案

端智能研发效率提升

完善研发工具生态，使算法能够脱离终端技术栈自主完成核心主链路的开发与调试，终端聚焦于应用逻辑，两者解耦



端智能技术体系总览

端智能研发工具生态

JSY 工作台

语法高亮 代码补全 语法纠错 方法跳转 本地编译 连接管理 项目管理 资源展示 本地部署 日志重定向

端数据中心

离线特征共享

硬件特征 上下文特征 行为特征 画像特征 生成特征

高性能数据通道

顺序校正 订阅分发 同步异步 质量监测 通道管理

JSY 脚本引擎

基础语法 内置API 插件工作台 联调测试 性能优化

事件标准化

标准格式 统一登记 文件生成 查看搜索 读写接口

大同

参数绑定 事件检测 完备性处理 时机统一 数据校验

端智能基础

资源管理

打包流水线 资源发布 灰度支持 版本管理

算法动态化

配置解析 推理控制 数据收集 场景关联

模型管理

模型下载 模型更新 模型加载 模型删除

推理引擎

端推理 端训练 配置解析 数据处理



TF Lite



TNN



CORE ML

容灾与监控

服务监控

链路日志 服务降级

特征监控

容量占用 价值评估

数据中心监控

任务耗时 异常统计

模型性能监控

拉取耗时 加载成功率

云服务基础

TDS-Shiply

资源管理



DataInsight

数据分析



TAB实验平台

实验平台

为什么要端数据中心



数据生产


终端事件自动化采集
规范化定义
准确性保证
更低的开发测试成本




数据消费

选择与订阅
流处理（条件过滤/匹配/聚合）
批处理（CURD）
动态化与性能的平衡

端上数据生产的挑战



大同数据-目标




大同数据-规范性定义




大同数据-核心流程

参数绑定



- 将上报参数绑定至对应实体对象
- 为后续步骤做准备


事件触发检测



- 以触发检测代替直接触发上报，防止多报，提高准确性
- 使用 AOP 触发检测有效减少漏报同时降低开发成本

准确性


信息完备性处理



- 标准化上下文信息收集，降低参数收集成本
- 标准化来源信息收集，降低开发成本、提高来源信息的规范性

开发/维护低成本

数据校验




- 详细的元数据登记系统提高规范性
- 全流程校验工具提高数据准确性、规范性

规范性

大同数据-校验流程



- 蓝色：需求管理流
- 橙色：数据质量管理流




端智能场景下的数据消费



数据中心全景



JSY 触发器



为什么不用JS虚拟机

终端流处理场景特点

1 数据流密集

端内时时刻刻在产生源事件，在一些场景下同时涌入的事件量级尤其大


2 数据传递多

原生数据往往需要传递到脚本执行环境内进行加工处理

3 与原生交互频繁

JS内的逻辑处理往往依赖原生提供的API

JS与原生交互示意图



JSY脚本引擎-目标

1.面向流处理

2.原生交互无损

3.语法简洁

4.包体轻量


5.高阶算子支持

6.语法扩展性



JSY核心优势

- ✓ 极致预编译
- ✓ 共享数据内存
- ✓ 无上下文切换成本
- ✓ 符号预解析index化



JSY脚本编译优化


```
var prefix = "HE" + "LLO";  
var suffix = "JSY";  
return greet(prefix, suffix);
```

```
inline function greet(prefix, suffix) {  
    return prefix + " My " + suffix;  
}
```

△小西泉


代码

JSY脚本编译优化



JSY脚本编译优化


1. 语法树剪枝



JSY脚本编译优化


1.语法树剪枝

2.全局传播




JSY脚本编译优化

- 1.语法树剪枝
- 2.全局传播
- 3.函数内联




JSY脚本编译优化

- 1.语法树剪枝
- 2.全局传播
- 3.函数内联
- 4.常量折叠



JSY脚本编译优化

- 1.语法树剪枝
- 2.全局传播
- 3.函数内联
- 4.常量折叠
- 5.常量传播



JSY脚本编译优化


1.语法树剪枝

2.全局传播

3.函数内联

4.常量折叠

5.常量传播



JSY脚本引擎-性能比较

```
{
  {
    "元素ID": "xxx"
    "版本号": "8940",
    ...其他基础公参
    "业务参数": {
      "页面" {
        "pgid": "page",
        ...其他页面私参
      },
      "视频ID": "xxx",
      "内容ID": "xxx",
      "模块ID": "xxx",
      ...其他业务私参
    }
  }
}
```

数据样例
10KB大小

J2V8 耗时
316.47ms

JSC 耗时
74.15ms

J2V8 峰值内存
3.3MB

JSC 峰值内存
3.9MB

J2V8 包大小
35.1MB

降低
99.15%

降低
88.55%

降低
99.15%

降低
99.74%

降低
99.76%

JSY 耗时
316.47ms

JSY 耗时
8.49ms

JSY 内存
0.3MB

JSY 内存
0.01MB

JSY 包大小
0.085MB

Android

iOS

Android

iOS


Android

 处理耗时

 峰值内存

 包大小

算法过程全动态化



推理引擎选择



TensorFlow Lite

对算法友好，泛用性更强
工具链生态完善



TNN

端训练客制化支持




CORE ML

原生提供开箱即用的算法集（VisionKit等）


因地制宜地选择最适合的方案

大盘监控体系


数据中心脚本耗时(ms)




推理设备分布





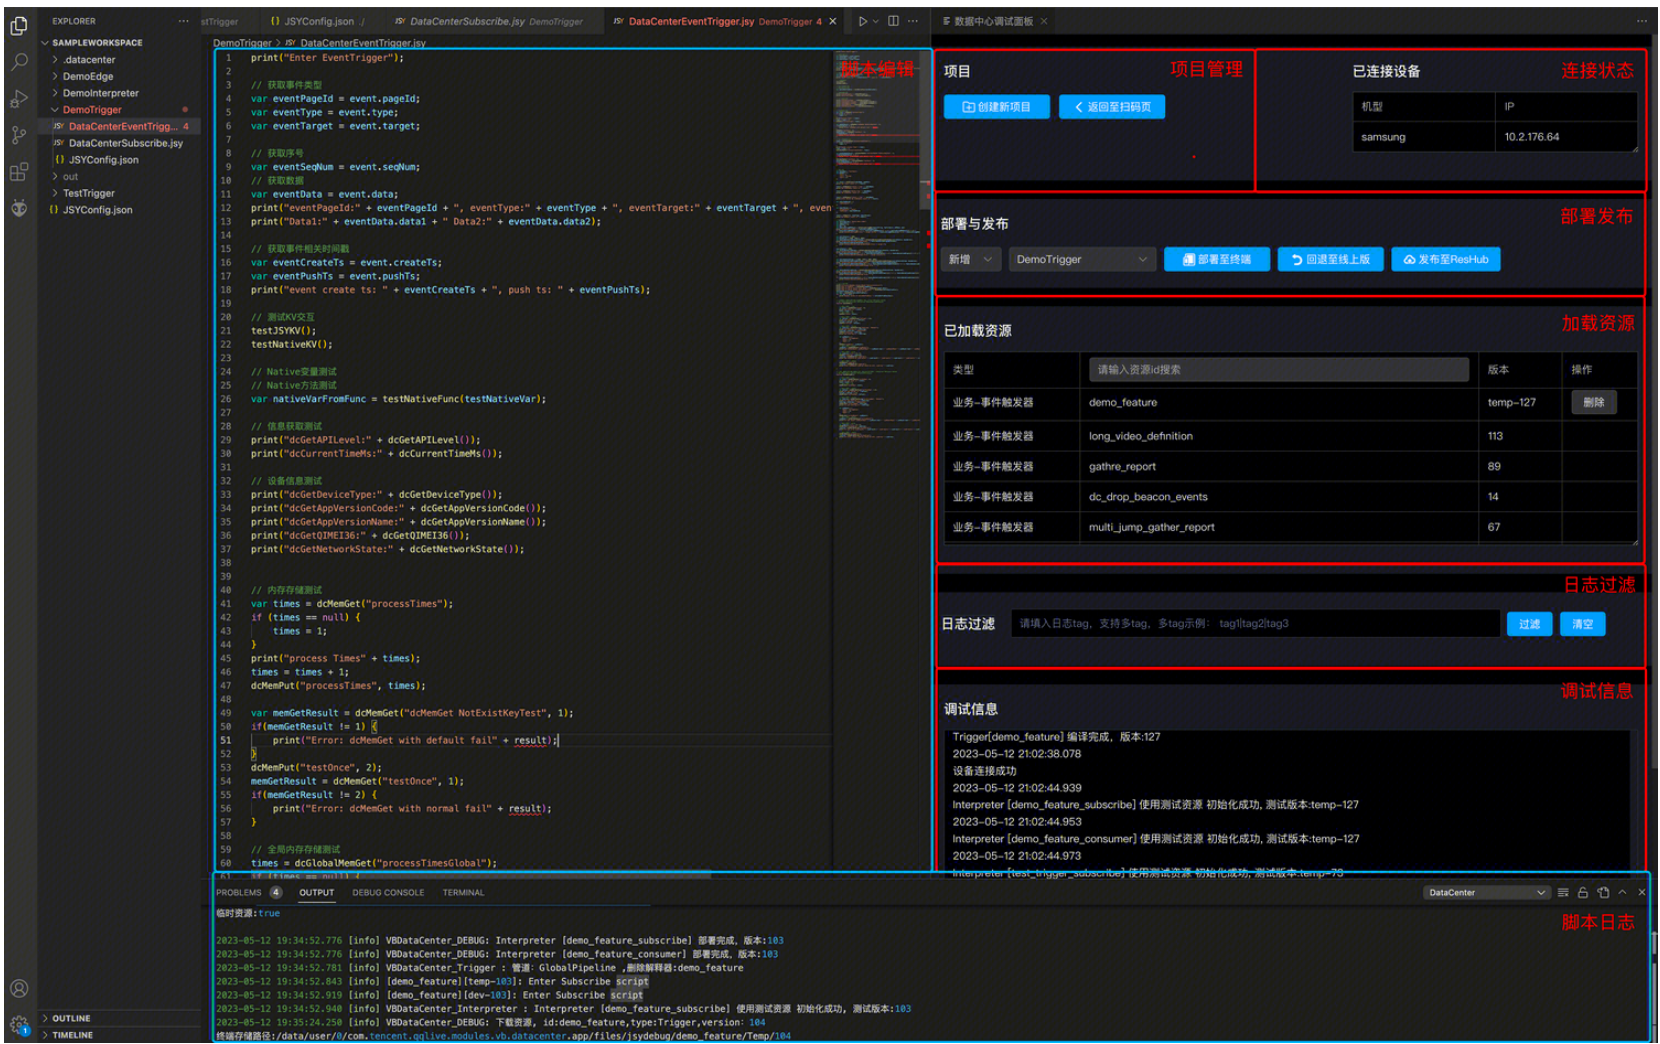
触发器消费占比



推理执行耗时(ms)



JSY工作台插件




- ✓ 端内真实环境实时联调
- ✓ 编码体验增强
- ✓ 实时资源部署替换
- ✓ 一键发布、验证



开发人效
+40%

端智能场景协同对比

优化前



优化后



业务落地提效近2倍


业务实践成果

端上重排

人均时长提升 ↑




人均播放次数提升 ↑



智能预上传


图片帖发表量提升（5%左右）

视频发表量提升（5%左右）



视频编辑完成

发布前，需要上传剪辑好的视频。
预上传可以减少用户的等待时间，提升用户体验。
但用户最终未选择发布，则预上传反而造成了资源浪费。




降本增效

离线指标计算耗时
-90%

大数据处理成本-5%


人均播放次数提升




未来规划

规划

 更多场景覆盖



 AIGC终端探索



THANKS

软件正在重新定义世界

Software Is Redefining The World